

Лабораторна робота 1

з курсу “Інтелектуальний аналіз даних”

Початковий аналіз даних та візуалізація засобами Python

МЕТА: вивчення методики визначення статистичних характеристик набору даних та проведення візуалізації даних, розглянути використання бібліотек numpy, pandas, matplotlib для роботи з даними.

Статистика - наука про навчання на основі даних, про вимірювання, контроль та тлумачення невизначеності; має важливе значення для управління ходом наукових і соціальних досягнень. Статистика допомагає оцінити варіативність та зменшити невизначеність. Розрізняють описову та вивідну статистики.

- Описова - вивчає властивості спостережуваних даних.
- Вивідна статистика – виводимо припущення про властивості розподілу даних з яких походять спостережувані дані

Розглянемо основні етапи роботи з тестовим набором даних.

Для початку потрібно імпортувати чотири бібліотеки numpy, pandas, Scikitlearn, matplotlib.

- Numpy - це бібліотека для обчислень з підтримкою високорівневих обчислень
- Pandas – це бібліотека для роботи з даними на Python, що надає інструменти для читання та запису даних у різних форматах, включаючи CSV, Excel і багато інших
- Scikit-learn – це бібліотека для машинного навчання в Python, що надає інструменти для класифікації, регресії, кластеризації, зменшення розмірності і багато іншого
- Matplotlib - бібліотека для візуалізації даних в Python, що надає інструменти для створення різних типів графіків, включаючи лінійні графіки, стовпчасті графіки, кругові діаграми, гістограми та інші.
-

```
import numpy as np
import pandas as pd
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt
```

Імпорт даних

Завантажте файл "flats.csv" з сервера та помістіть у ту ж папку, де знаходиться створений вами проєкт. Завантажте дані з файла "flats.csv" у змінну flats використовуючи функцію read.csv.

```
df = pd.read_csv('flats.csv')
```

Дослідження даних

Розглянемо деякі функції для роботи з даними. Для того, щоб знайти певні характеристики набору, використовують спеціальні функції.

Візуалізація даних

Для візуалізації даних будемо використовувати бібліотеку `matplotlib.pyplot`. Цей код використовує бібліотеку `Pandas` та `Matplotlib` для створення стовпчикової діаграми гістограми кількості квартир з певною загальною площею.

1. Завантаження даних з файлу "flats.csv" у змінну `df`, використовуючи функцію `pd.read_csv()`.
2. Відбір перших 15 значень зі стовпця `Square` за допомогою методу `.head(15)` та визначення кількості значень, що зустрічаються, за допомогою методу `.value_counts()`.
3. Побудова стовпчикової діаграми за допомогою методу `.plot()`, де параметр `kind` встановлюється як "bar", щоб відобразити діаграму стовпців.
4. Параметр `rot` встановлюється як 45 градусів, щоб повернути підписи осі X для зручного читання.
5. Встановлення заголовку графіку за допомогою методу `.title()`, підписів вісей X та Y за допомогою методів `.xlabel()` та `.ylabel()` відповідно.
6. Відображення графіку за допомогою методу `plt.show()`.

```
import pandas as pd
import matplotlib.pyplot as plt


df = pd.read_csv('flats.csv')

df['Square'].head(15).value_counts().plot(kind='bar', rot=45)

plt.title('Гістограма кількості Кімнат у містах України')
plt.xlabel('Місто')
plt.ylabel('Кількість')

plt.show()
```


Перші 15 міст



Останні 15 міст

Тут все те саме що в минулому коді, але щоб вибрати останні 15 міст потрібно написати наступний код

```
df['Square'].tail(15).value_counts().plot(kind='bar', rot=45)
```



Якщо міста містяться у стовпці "City" у датафреймі df, то для того, щоб дізнатись загальну кількість міст, можна використати метод `nunique()` наступним чином:

```
num_cities = df['City'].nunique()
print("Загальна кількість міст: ", num_cities)
```

Загальна кількість міст: 13

Щоб отримати інформацію про кількість трьохкімнатних квартир в Одесі потрібно використати фільтрацію даних у змінній df за умовою "кількість кімнат = 3" та "місто = Одеса", тобто:

```
df[(df['rooms'] == 3) & (df['city'] == 'Одеса')].shape[0]
```

Цей код фільтрує рядки у змінній df тільки зі значенням "кількість кімнат = 3" та "місто = Одеса", а потім повертає кількість рядків за допомогою .shape[0], що відповідає кількості трьохкімнатних квартир в Одесі.

```
Кількість трьохкімнатних квартир у місті Одеса: 11
```


Проведемо візуалізацію набору даних. Наступний код використовує бібліотеки Pandas та Matplotlib для завантаження даних з CSV-файлу та побудови графіка розсіювання.

```
import pandas as pd
import matplotlib.pyplot as plt

# Завантаження даних з CSV-файлу в DataFrame
df = pd.read_csv('flats.csv')

# Побудова графіку розсіювання
plt.figure(figsize=(10, 8)) # Задання розміру графіка
plt.scatter(df['Square'].head(50), df['Price'].head(50)) # Вибір
стовпців для вісей X та Y
plt.title('Графік розсіювання: Залежність ціни від загальної
площі') # Додавання заголовку
plt.xlabel('Загальна площа, м²') # Підпис вісі X plt.ylabel('Ціна,
грн') # Підпис вісі Y
plt.show() # Відображення графіка
```

1. Спочатку імпортується дві бібліотеки Pandas та Matplotlib.
2. Далі завантажується CSV-файл "flats.csv" в об'єкт DataFrame, який зберігається у змінній df за допомогою функції pd.read_csv(). Файл містить дані про квартири, включаючи загальну площу та ціну.
3. Потім задається розмір графіка за допомогою функції plt.figure(). Розмір графіка складає 10 на 8 дюймів.
4. Наступним кроком є побудова графіка розсіювання за допомогою функції plt.scatter(). Графік будується з використанням перших 50 рядків даних про стовпці Square та Price. Стовпець Square використовується для вісі X, а Price - для вісі Y.
5. Далі додається заголовок до графіка за допомогою функції plt.title().
6. Далі задаються підписи вісей X та Y за допомогою функцій plt.xlabel() та plt.ylabel() відповідно.
7. Нарешті, графік відображається на екрані за допомогою функції plt.show().



Наступний код завантажує дані з CSV-файлу "flats.csv" у форматі DataFrame за допомогою бібліотеки pandas та побудовує гістограму цін на квартири за допомогою бібліотеки matplotlib.

```
import pandas as pd
import matplotlib.pyplot as plt

# Завантаження даних з CSV-файлу в DataFrame
df = pd.read_csv('flats.csv')

# Побудова гістограми
plt.figure(figsize=(8, 6)) # Задання розміру графіка
plt.hist(df['Price'].head(20), bins=20, color='skyblue',
         edgecolor='black') # Вибір стовпця та налаштування вигляду
                             # гістограми
plt.title('Гістограма цін на квартири') # Додавання заголовку
plt.xlabel('Ціна, грн') # Підпис вісі X
plt.ylabel('Кількість') # Підпис вісі Y
plt.show() # Відображення графіка
```

1. `import pandas as pd` та `import matplotlib.pyplot as plt` імпортують бібліотеки pandas та matplotlib.pyplot відповідно.

2. `df = pd.read_csv('flats.csv')` завантажує дані з CSV-файлу "flats.csv" та зберігає їх у змінну df, яка представляє DataFrame.


3. `plt.figure(figsize=(8, 6))` створює нову фігуру з заданим розміром.

4. `plt.hist(df['Price'].head(20), bins=20, color='skyblue', edgecolor='black')` створює гістограму за допомогою функції `hist()` з використанням даних зі стовпця "Price" та встановлює параметри вигляду: `bins` встановлює кількість бінів гістограми, `color` встановлює колір гістограми, `edgecolor` встановлює колір граней гістограми.

5. `plt.title('Гістограма цін на квартири')` додає заголовок до гістограми.

6. `plt.xlabel('Ціна, грн')` та `plt.ylabel('Кількість')` додають підписи до вісей X та Y відповідно.

7. `plt.show()` відображує створену гістограму.




Гістограма за площами (приклад невдалого типу графіка для візуалізації)

```
import pandas as pd
import matplotlib.pyplot as plt


df = pd.read_csv('flats.csv')

df['Square'].head(50).value_counts().plot(kind='bar', rot=45)

plt.title('Кількість квартир за площею') plt.xlabel('Площа')
plt.ylabel('Кількість квартир')
plt.show()
```



Приклад коробчастої діаграми, побудованої засобами `matplotlib.pyplot`:



Завдання на лабораторну роботу

1. Провести первинну обробку, аналіз та візуалізацію статистичних даних, використовуючи тестові дані з файлу flats.csv.

- Знайдіть кількість вимірів датафрейму flats.
- Відобразіть перші шість рядків, перші п'ятнадцять рядків, останні шість рядків.

рядків.

- Відобразіть імена датафрейму
- Скільки змінних у наборі даних flats?
- Яка кількість міст у наборі даних flats?
- Чи всі з них дійсно є містами?
- Яка кількість трикімнатних квартир продається в місті Одеса?
- Яка медіана площі однокімнатної квартири в місті Львів?

2. Провести візуалізацію набору даних.

- Побудуйте стовпчикову діаграму для змінної загальна площа
- Побудуйте коробчатую діаграму для візуалізації розподілу цін в залежності від кількості кімнат
- Побудуйте графік розсіювання, який відображатиме залежність ціни від загальної площі
- Побудуйте гістограму для оцінки розподілу ціни квартир

Захист лабораторної роботи проводиться при наявності звіту у встановлені терміни.