

Лабораторна робота №1- 2

з курсу “Інтелектуальний аналіз даних”

ТЕМА: Статистичний аналіз засобами мови R. Кореляційний аналіз даних в R-студіо

МЕТА: вивчення методики визначення статистичних характеристик набору даних та проведення кореляційного аналізу в R-Studio.

Теоретичні відомості

Статистика - наука про навчання на основі даних, про вимірювання, контроль та тлумачення невизначеності; має важливе значення для управління ходом наукових і соціальних досягнень.

Статистика допомагає оцінити варіативність та зменшити невизначеність. Розрізняють описову та вивідну статистику.

- Описова - вивчає властивості спостережуваних даних.
- Вивідна статистика – виводимо припущення про властивості розподілу даних з яких походять спостережувані дані

Мова R

R це мова програмування, яка широко використовується для аналізу даних. В даній роботі ми будемо використовувати бібліотеки

- dplyr: для очищення та трансформації даних
- ggplot2: для візуалізації даних

Ці бібліотеки завантажуються з допомогою команди `install.packages`. Створіть новий файл (File -> New File -> RScript) та скопіюйте наступні рядки:

```
install.packages("dplyr")  
install.packages("ggplot2")
```

Щоб виконати код, виділіть рядки та натисніть піктограму Run з зеленою стрілкою або комбінацію клавіш CTRL + ENTER або COMMAND + ENTER.

Далі завантажте ці бібліотеки до вашого робочого середовища. Це можна зробити з допомогою функції `library`. Зауважте, що ми встановлюємо бібліотеку один раз, але завантажувати її потрібно щоразу, як ви перезапускаєте RStudio. Тобто при наступному запуску RStudio команди інсталяції не будуть потрібні і їх можна буде закоментувати використовуючи символ #:

```
#install.packages("dplyr")  
#install.packages("ggplot2")
```

Додайте рядки:

```
library(dplyr)
library(ggplot2)
```

Імпорт даних

Завантажте файл "flats.csv" з сервера та помістіть у ту ж папку, де знаходиться створений вами RScript. Завантажте дані з файла "flats.csv" у змінну flats використовуючи функцію read.csv.

```
#getwd()
setwd("D:/lab1/")
flats <- read.csv(file = "flats.csv", header = TRUE,
stringsAsFactors=FALSE, dec= ",", encoding="UTF-8")
```

Параметр stringsAsFactors=FALSE вказує, що змінні, які мають тип character не будуть перетворюватись у тип даних factor.

Команда setwd (скорочення від set working directory) дозволяє не вказувати повний шлях до цієї директорії.

Визначимо клас об'єкта flats з допомогою команди class()

```
class(flats)
## [1] "data.frame"
```

Клас об'єкта flats data.frame або ж таблиця даних. Кожен рядок цієї таблиці репрезентує спостереження, а кожна колонка відображає змінну, тобто частину інформації про це спостереження. В R ви можете використовувати функцію str(скорочення від structure) щоб швидко оцінити, чи правильно зчиталися ваші дані.

```
str(flats)
## 'data.frame':   839 obs. of  4 variables:
## $ Місто       : chr  "Вінниця" "Вінниця" "Вінниця" "Вінниця" ...
## $ Кімнат      : int   3 3 2 2 3 1 3 3 1 6 ...
## $ Загальна_площа: num  120 66 66 44 63 31 46 64 35 200 ...
## $ Ціна        : num  1875000 975000 1375000 637500 835000 ...
```

Дослідження даних

Розглянемо деякі функції для роботи з даними. Для того, щоб знайти кількість вимірів, використовується функція dim()

- head() відображає першу частину об'єкта, першим параметром є об'єкт(тут таблиця даних flats, другим параметром можна вказати кількість рядків)

- `tail()` відображає останню частину об'єкта, теж можна вказати кількість рядків
- `names()` імена, пов'язані з об'єктом
- `summary()` щоб отримати перші знання про таблицю.
- функція `glimpse()` для швидкого узагальнення таблиці.

```
# View a summary of flats
```

```
summary(flats)
```

```
##      Місто      Кімнат  Загальна_площа      Ціна
## Length:839      Min.   :1.000      Min.   : 14.00      Min.   : 10200
## Class :character 1st Qu.:1.000      1st Qu.: 43.75      1st Qu.: 537500
## Mode  :character Median :2.000      Median : 56.00      Median : 775000
##                      Mean  :2.045      Mean  : 64.07      Mean  :1042710
##                      3rd Qu.:3.000      3rd Qu.: 75.00      3rd Qu.:1200000
##                      Max.   :6.000      Max.   :222.60      Max.   :12250000
```

```
# Get a glimpse of flats
```

```
glimpse(flats)
```

```
## Observations: 839
```

```
## Variables: 4
```

```
## $ Місто      <chr> "Вінниця", "Вінниця", "Вінниця", "Вінниця", "Ві...
```

```
## $ Кімнат      <int> 3, 3, 2, 2, 3, 1, 3, 3, 1, 6, 2, 1, 1, 2, 3, 3,...
```

```
## $ Загальна_площа <dbl> 120.00, 66.00, 66.00, 44.00, 63.00, 31.00, 46.0...
```

```
## $ Ціна        <dbl> 1875000, 975000, 1375000, 637500, 835000, 56250...
```

Дізнаємося, яка кількість квартир продається у кожному місті(згідно цього набору даних):

В бібліотеці `dplyr` для цього є функція `count`:

```
count(flats, Місто)
```

```
## # A tibble: 13 × 2
```

```
##           Місто      n
```

```
##           <chr> <int>
```

```
## 1      Вінниця    275
```

```
## 2  Дніпропетровськ    18
```

```
## 3      Запоріжжя     13
```

```
## 4  Івано-Франківськ    47
```

```
## 5  Києво-Святошинський    19
```

```
## 6      Київ     186
```

Києво-Святошинський район виділений в окреме місто. Вилучимо ці дані з відображення використовуючи команду `filter` (умова дорівнює позначається як `==`, а не дорівнює як `!=`)

Відсортуємо результати в спадаючому порядку для цього вкажемо `arrange(desc(n))`.

```
flats %>%
  filter(Місто != "Києво-Святошинський") %>%
  filter(Кімнат == 3) %>%
  count(Місто) %>%
  arrange(desc(n)) # arrange - сортування, desc - спадячий порядок
```

Можна обчислити середньоквадратичне відхилення з допомогою функції sd:

```
flats %>%
  filter(Кімнат == 2) %>%
  filter(Місто != "Києво-Святошинський") %>%
  summarise(mean(Загальна_площа), sd(Загальна_площа))

##   mean(Загальна_площа) sd(Загальна_площа)
## 1              60.81832             16.61458
```

Візуалізація даних:


Для візуалізації даних будемо використовувати бібліотеку ggplot2. В процесі розвідувального аналізу даних (Exploratory Data Analysis) процеси очищення та візуалізації даних є циклічними. Для побудови графіків використовується функція ggplot(). Після виконання коду ви побачите графік у вкладці Plots у нижній правій панелі в RStudio.

- Першим аргументом цієї функції є набір даних (dataset)
- Далі ми вказуємо змінні з набору даних як параметр aesthetic, які будуть відображатись, наприклад, по осях x та y

• Наступним кроком ми додаємо ще один рівень (об'єднавши їх знаком +) щоб задати geometric об'єкт. Наприклад, для графіка розсіювання це geom_point, для лінійного графіка geom_line, для стовпчикової діаграми geom_bar

Побудуємо стовпчикову діаграму для кількості кімнат


```
ggplot(flats, aes(x=Кімнат)) +  
  geom_bar(fill="lightblue",  
           col="grey") +  
  ylab('Кількість')
```



Графік розсіювання. Побудуємо графік залежності ціни від загальної площі.

```
library(ggplot2)
```

```
ggplot(flats, aes(x=Загальна_площа, y=Ціна)) + geom_point()
```



Коваріація та кореляція

Перейдемо до аналізу взаємозв'язків між двома змінними.

Коваріація – міра лінійної залежності двох випадкових величин одна від одної.

Кореляція – зважена версія коваріації.

Коефіцієнт кореляції (ще має назву коефіцієнт Пірсона) обчислюється за формулою:

$$r = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X)}\sqrt{\text{var}(Y)}} = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}}$$

В R коефіцієнт для обчислення коефіцієнта кореляції використовується функція `cor`, яка по замовчуванню рахує коефіцієнт кореляції Пірсона(є й інші коефіцієнти кореляції).

Абсолютне значення коефіцієнта кореляції дає уявлення про силу лінійного зв'язку між двома змінними. Знак коефіцієнта вказує напрямок зв'язку. Коефіцієнт кореляції набуває значень $[-1, 1]$. Якщо коефіцієнт близький до 1 - говорять про сильну позитивну кореляцію, до -1 про сильну негативну. Значення коефіцієнта близькі до 0 вказують на відсутність лінійної кореляції.

Властивості коефіцієнта кореляції:

- коефіцієнт кореляції не змінюється при зміні одиниць виміру(наприклад від кілограм до грам)
- коефіцієнт кореляції є симетричним $r(x, y) = r(y, x)$
- коефіцієнт кореляції чутливий до викидів

Лінійна регресія


Якщо коефіцієнт кореляції дає нам розуміння чи є лінійна залежність між двома змінними, то *лінійна регресія* дає модель для оцінки як зміниться одна змінна при зміні іншої.

Наприклад, може визначити, як вага дорослої анаконди при зміні її довжини.

```
anaconda <- read.csv("anaconda.dat", sep=" ", header =  
FALSE)  
colnames(anaconda) <- c("Height", "Weight", "Sex")
```

Побудуємо графік розсіювання для наших даних:

```
ggplot(anaconda, aes(x=Height, y=Weight)) +  
  geom_point(col="blue")
```



На основі цього графіка, можемо припустити, що є позитивна лінійна залежність між довжиною та вагою дорослих анаконд.

Знайдемо коефіцієнт кореляції:

```
cor(anaconda$Height, anaconda$Weight)
## [1] 0.9613875
```

Дійсно, ці дві змінні мають сильну позитивну лінійну залежність.

Лінійна регресія передбачає що ми побудуємо лінію, яка якнайкраще описуватиме наші дані. Формула цієї лінії:

$$y = ax + b$$

де x - незалежна змінна (в нашому прикладі це довжина), y - залежна змінна (вага анаконд). a - це кут нахилу цієї прямої (slope) b - точка перетину з y , де $x = 0$ (intercept)

Як знайти цю лінію? Через ці точки можна провести безліч ліній, один з найчастіше вживаних для побудови "найкращої лінії" - **метод найменших квадратів**. Серед всіх ліній, найкращою вважається та, сума квадратів залишків якої є найменшою.

Є формули для обчислення коефіцієнтів a та b . Однак ми скористаємось функціоналом R.

Для знаходження найкращої лінії, яка й буде нашою моделлю, будемо використовувати функцію `lm`. Вказуємо формулу залежності `Weight ~ Height` – означає, що ми будуємо лінійну модель залежності змінної `Weight` від змінної `Height`.

```
prediction_model <- lm(Weight ~ Height, data=anaconda)
```

Для оцінки результатів лінійної моделі використовується функція `summary`:

```
summary(prediction_model)
```

Давайте подивимось, яку інформацію про модель ми отримали:

```
##
## Call:
## lm(formula = Weight ~ Height, data = anaconda)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -9.2050  -3.9127  -0.2454   1.9430  16.8067
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -50.730584   2.946034  -17.22  <2e-16 ***
## Height       0.253047   0.009857   25.67  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 5.754 on 54 degrees of freedom
## Multiple R-squared:  0.9243, Adjusted R-squared:  0.9229
## F-statistic: 659 on 1 and 54 DF, p-value: < 2.2e-16
```

модель

статистична значимість коефіцієнтів(розглянемо пізніше)

R^2

a

b

Значення коефіцієнта Height(відповідає a в загальній моделі $y = ax + b$) становить 0.253, Intercept(відповідає b) становить -50.73. Тобто формула залежності ваги анаконди від її довжини:


$$\text{Weight} = 0.253\text{Height} - 50.73$$

Це означає, що при збільшенні довжини на 1 см, вага збільшується на 0.253 кг або ж 253 грами.

Також досить корисним для трактування результатів є коефіцієнт R^2 . Рахується як квадрат коефіцієнта кореляції, тому має значення від 0 до 1. Основна його цінність у тому, що він говорить, який відсоток варіативності залежної змінної пояснюється лінійною моделлю. Відповідно залишок пояснюється змінними, які не включені в модель. Для лінійної моделі залежності ваги анаконд від їх довжини залишок складає 8%. До змінних, які можуть покращити модель належить, наприклад, стать або вік цих анаконд.

Також в `ggplot2` (як і в базовому функціоналі R) лінію регресії можна додати до графіка розсіювання:

```
ggplot(anaconda, aes(x=Height, y=Weight)) +
geom_point(col="blue") + geom_smooth(method = "lm", se=FALSE)
```



Умови для побудови лінійної регресії:

- Лінійність (тобто наявність лінійної залежності між незалежною та залежною змінною)
- Нормальний розподіл залишків
- Гомоскедастичність (стала варіативність залишків)

За цим посиланням https://gallery.shinyapps.io/slr_diag/ ви можете змоделювати дані з різними типами залежності та дослідити, як при цьому будуть виглядати лінія регресії, коефіцієнт кореляції, R_a , та як виглядає розподіл залишків.

Завдання на лабораторну роботу

1. Провести первинну обробку, аналіз та візуалізацію статистичних даних в системі R-Studio, використовуючи тестові дані з файлу flats.csv.

- Знайдіть кількість вимірів датафрейму flats.
- Відобразіть перші шість рядків, перші п'ятнадцять рядків, останні шість рядків.
- Відобразіть імена датафрейму
- Скільки змінних у наборі даних flats?

- Яка кількість міст у наборі даних flats?
- Чи всі з них дійсно є містами?
- Яка кількість трикімнатних квартир продається в місті Одеса?
- Яка медіана площі однокімнатної квартири в місті Львів?

2. Провести візуалізацію набору даних.

- Побудуйте стовпчикову діаграму для змінної загальна площа
- Побудуйте коробчатую діаграму для візуалізації розподілу цін в залежності від кількості кімнат
- Побудуйте графік розсіювання, який відображатиме залежність ціни від загальної площі
- Побудуйте гістограму для оцінки розподілу ціни квартир

3. Провести кореляційний аналіз даних для набору даних anaconda.dat за вказівками, наведеними в теорії.

За посиланням https://gallery.shinyapps.io/slr_diag/ провести аналіз даних з різними типами залежності та дослідити, як при цьому будуть виглядати лінія регресії, коефіцієнт кореляції, R^2 , та як виглядає розподіл залишків.

Вимоги до оформлення звіту

Захист лабораторної роботи проводиться при наявності звіту. Захист роботи виконується у встановлені терміни. Звіт повинен бути оформлений на папері стандартного формату А4

Звіт повинен містити такі розділи:

1. Постановку задачі, розв'язування якої виконується на лабораторній роботі.
2. Короткий опис основних теоретичних положень та алгоритмів, що застосовуються для розв'язування поставленої задачі та будуть використані при реалізації завдань.
3. Контрольні приклади та результати їх виконання. Контрольні приклади повинні ілюструвати роботу програми та ситуації, при яких алгоритм не застосовний. Контрольні приклади готуються студентом. Під час захисту лабораторної роботи студент повинен продемонструвати працездатність своєї програми на контрольних прикладах. Викладач може запропонувати свої приклади для перевірки працездатності програми.