

Лабораторна робота 2

з курсу “Інтелектуальний аналіз даних”

Регресійний аналіз даних та візуалізація засобами Python

МЕТА: вивчення методики визначення характеристик набору даних та проведення кореляційного аналізу даних, розглянути використання бібліотек `numpy`, `pandas`, `matplotlib` для роботи з даними.

Коваріація та кореляція

Перейдемо до аналізу взаємозв'язків між двома змінними.

Коваріація – міра лінійної залежності двох випадкових величин одна від одної.

Кореляція – зважена версія коваріації.

Коефіцієнт кореляції (ще має назву коефіцієнт Пірсона) обчислюється за формулою:

В R коефіцієнт для обчислення коефіцієнта кореляції використовується функція `cor`, яка по замовчуванню рахує коефіцієнт кореляції Пірсона (є й інші коефіцієнти кореляції). Абсолютне значення коефіцієнта кореляції дає уявлення про силу лінійного зв'язку між двома змінними. Знак коефіцієнта вказує напрямок зв'язку. Коефіцієнт кореляції набуває значень $[-1, 1]$. Якщо коефіцієнт близький до 1 - говорять про сильну позитивну кореляцію, до -1 про сильну негативну. Значення коефіцієнта близькі до 0 вказують на відсутність лінійної кореляції.

Властивості коефіцієнта кореляції:

- коефіцієнт кореляції не змінюється при зміні одиниць виміру (наприклад від кілограм до грам)
- коефіцієнт кореляції є симетричним $r(x, y) = r(y, x)$
- коефіцієнт кореляції чутливий до викидів

Лінійна регресія

Якщо коефіцієнт кореляції дає нам розуміння чи є лінійна залежність між двома змінними, то лінійна регресія дає модель для оцінки як зміниться одна змінна при зміні іншої. Наприклад, може визначити, як вага дорослої анаконди при зміні її довжини.

Лінійна регресія передбачає що ми побудуємо лінію, яка якнайкраще описуватиме наші дані. Формула цієї лінії: $y = ax + b$, де x - незалежна змінна (в

нашому прикладі це довжина), y - залежна змінна (вага анаконд). a - це кут нахилу цієї прямої (slope) b - точка перетину з y , де $x = 0$ (intercept)

Як знайти цю лінію? Через ці точки можна провести безліч ліній, один з найчастіше вживаних для побудови "найкращої лінії" - метод найменших квадратів. Серед всіх ліній, найкращою вважається та, сума квадратів залишків якої є найменшою.

Наступний код д використовує бібліотеку pandas для завантаження даних з файлу anaconda.dat, а потім проводить кілька операцій з даними.

```
import pandas as pd

# Завантаження даних з файлу anaconda.dat
df = pd.read_csv('anaconda.dat', sep='\t', names=['X', 'Y', 'Gender'])

# Виведення перших 5 рядків даних
print(df.head())

# Перевірка типів даних у колонках
print(df.dtypes)

# Заміна значень "М" та "Ф" на відповідно числові значення
df['Gender'] = df['Gender'].map({'M': 0, 'F': 1})

# Перевірка заміни значень
print(df.head())

# Розрахунок коефіцієнта кореляції Пірсона
correlation = df.corr()

# Виведення матриці кореляції
print(correlation)
```

1. `pd.read_csv('anaconda.dat', sep='\t', names=['X', 'Y', 'Gender'])`: Цей рядок завантажує дані з файлу anaconda.dat з використанням роздільника табуляції ('\t') та встановлює назви стовпців на 'X', 'Y', та 'Gender'. Функція `pd.read_csv()` повертає об'єкт `DataFrame`, який зберігає ці дані.

2. `print(df.head())`: Цей рядок виводить перші п'ять рядків з `DataFrame` `df`, який містить завантажені дані.

3. `print(df.dtypes)`: Цей рядок виводить типи даних для кожного стовпця `DataFrame` `df`.

4. `df['Gender'] = df['Gender'].map({'M': 0, 'F': 1})`: Цей рядок змінює значення в стовпці 'Gender', замінюючи значення 'M' на 0 та 'F' на 1.

5. `print(df.head())`: Цей рядок виводить перші п'ять рядків DataFrame `df` після заміни значень в стовпці 'Gender'.

6. `correlation = df.corr()`: Цей рядок обчислює матрицю кореляції для всіх стовпців у DataFrame `df` та зберігає її в змінну `correlation`.

`print(correlation)`: Цей рядок виводить матрицю кореляції, яка містить коефіцієнти кореляції між кожною парою стовпців у DataFrame `df`.

```

      X      Y Gender
0  271.0  18.5      F
1  477.0  82.5      F
2  306.3  23.4      F
3  365.3  33.5      F
4  466.0  69.0      F
X      float64
Y      float64
Gender  object
dtype: object

      X      Y Gender
0  271.0  18.5      1
1  477.0  82.5      1
2  306.3  23.4      1
3  365.3  33.5      1
4  466.0  69.0      1

      X      Y Gender
X      1.000000  0.961387  0.766122
Y      0.961387  1.000000  0.729934
Gender 0.766122  0.729934  1.000000

Process finished with exit code 0

```

Наступний код будує лінійну регресію та виводить візуалізації для аналізу залежності між двома змінними.

1. Спочатку, імпортується необхідні бібліотеки `Pandas`, `NumPy`, `Matplotlib`, `LinearRegression` та `r2_score` з `scikit-learn`.
2. Далі, завантажується файл даних 'anaconda.dat' зі значеннями `X`, `Y` та `Gender` у DataFrame.
3. Замінюються значення 'M' та 'F' у колонці 'Gender' на відповідно числові значення 0 та 1.
4. Дані розділяються на окремі колонки `X` та `Y` та підготовлюються для побудови моделі лінійної регресії.
5. Лінійна регресія побудовується на основі значень `X` та `Y`.
6. Прогнозні значення `Y_pred` отримуються на основі моделі лінійної регресії.
7. Коефіцієнт кореляції Пірсона розраховується для оцінки ступеня лінійної залежності між змінними `X` та `Y`.

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

```

8. Коефіцієнт детермінації (R^2) розраховується для оцінки точності побудованої моделі.
9. Побудовується графік, який показує залежність між X та Y та включає лінію лінійної регресії.
10. Побудовується візуалізація залишків для перевірки на випадковість помилок моделі.

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score

# Завантаження даних з файлу anaconda.dat
df = pd.read_csv('anaconda.dat', sep='\t', names=['X', 'Y',
'Gender'])

# Заміна значень "M" та "F" на відповідно числові значення
df['Gender'] = df['Gender'].map({'M': 0, 'F': 1})

# Розділення даних на окремі колонки
X = df['X'].values.reshape(-1, 1)
Y = df['Y'].values

# Побудова лінійної регресії
regression = LinearRegression()
regression.fit(X, Y)


# Отримання прогнозованих значень
Y_pred = regression.predict(X)

# Розрахунок коефіцієнта кореляції Пірсона
correlation = df[['X', 'Y']].corr().iloc[0, 1]

# Розрахунок коефіцієнта детермінації ( $R^2$ )
r2 = r2_score(Y, Y_pred)

# Побудова графіка регресії
plt.scatter(X, Y, color='blue', label='Дані')
plt.plot(X, Y_pred, color='red', linewidth=2,
label='Лінійна регресія') plt.xlabel('X') plt.ylabel('Y')
plt.title(f'Лінійна регресія (кореляція={correlation},
 $R^2$ ={r2})') plt.legend() plt.show()

# Розрахунок та візуалізація залишків
residuals = Y - Y_pred
plt.scatter(X, residuals, color='green')
plt.axhline(y=0, color='red', linestyle='--')
plt.xlabel('X') plt.ylabel('Залишки')
plt.title('Розподіл залишків') plt.show()
```



Умови для побудови лінійної регресії:

- Лінійність (тобто наявність лінійної залежності між незалежною та залежною змінною)
- Нормальний розподіл залишків
- Гомоскедастичність (стала варіативність залишків)

За цим посиланням https://gallery.shinyapps.io/slr_diag/ ви можете змоделювати дані з різними типами залежності та дослідити, як при цьому будуть виглядати лінія регресії, коефіцієнт кореляції, R , та як виглядає розподіл залишків.

Завдання на лабораторну роботу

1. Провести кореляційний аналіз даних для набору даних `anaconda.dat` за вказівками, наведеними в теорії.

2. За посиланням https://gallery.shinyapps.io/slr_diag/ провести аналіз даних з різними типами залежності та дослідити, як при цьому будуть виглядати лінія регресії, коефіцієнт кореляції, R та як виглядає розподіл залишків.