

ЗВІТ

про виконання лабораторної роботи №3

«Дисперсійний аналіз даних (ANOVA)»

з дисципліни

«Інтелектуальний аналіз даних»


Студента групи КН-2327Б

Багрія-Белза Андрія

Мета роботи: Дослідити відмінності середніх значень ознак під впливом одного та кількох якісних факторів за допомогою однофакторного і двофакторного дисперсійного аналізу в Python.


Завдання 1: Дослідження зв'язку тембру голосу та зросту співаків (Voice.txt, One-Way ANOVA)

Для перевірки залежності зросту співаків від типу голосу було побудовано лінійну модель та проведено однофакторний дисперсійний аналіз (One-Way ANOVA). Для повної вибірки співаків отримано статистику $F = 54.31$ та досягнутий рівень значущості $p = 1.33 \times 10^{-22}$ ($p < 0.05$). З метою з'ясування природи цього ефекту проведено роздільний дисперсійний аналіз у межах кожної статі. Для жіночої підгрупи (Soprano та Alto) отримано $F = 1.44$, $p = 0.235$ ($p > 0.05$). Для чоловічої підгрупи (Tenor та Bass) отримано $F = 0.48$, $p = 0.492$ ($p > 0.05$). Оскільки всередині кожної статевої групи відмінності зросту за тембром голосу є статистично незначущими, виявлена на повній вибірці залежність є виключно артефактом статевого диморфізму (жінки в середньому нижчі за чоловіків).




Завдання 2: Дослідження кількості помилок щурів у лабіринті (rat.txt, Two-Way ANOVA)

Для оцінки одночасного впливу умов середовища (ENVIRNMNT) та генетичної лінії (STRAIN) щурів на кількість помилок у лабіринті (ERRORS) виконано двофакторний дисперсійний аналіз типу II (Type II Two-Way ANOVA). Фактор середовища виявився статистично значущим: $F = 5.82$, $p = 0.0267$ ($p < 0.05$). Фактор генетичної лінії також є статистично значущим: $F = 4.16$, $p = 0.0326$ ($p < 0.05$). Взаємодія факторів (ENVIRNMNT:STRAIN) є повністю незначущою: $F = 0.0084$, $p = 0.9916$ ($p > 0.05$). Це свідчить про суто адитивний вплив середовища та спадковості: умови обмеження підвищують кількість помилок однаковою мірою для кожної генетичної лінії, що підтверджується паралельністю ліній на графіку взаємодії.




Розподіл помилок щурів за середовищем та генетичною лінією



Завдання 3: Дисперсійний аналіз власного набору даних (Tips dataset, One-Way ANOVA)

Досліджено вплив дня тижня (day: Thur, Fri, Sat, Sun) на загальну суму чека (total_bill) відвідувачів ресторану. Попередню перевірку гомогенності дисперсій між групами здійснено за тестом Левена: $W = 0.665$, $p = 0.574$ ($p > 0.05$), що підтверджує коректність застосування дисперсійного аналізу. За результатами One-Way ANOVA встановлено статистично значущий вплив дня тижня на величину чека: $F = 2.77$, $p = 0.0425$ ($p < 0.05$). У вихідні дні (субота та неділя) спостерігається вищий середній рівень витрат клієнтів.



Висновок: На цій лабораторній роботі я опанував практичне застосування однофакторного та двофакторного дисперсійного аналізу (ANOVA) в екосистемі Python за допомогою бібліотек statsmodels та scipy. Я навчився оцінювати вплив якісних факторів та їхніх взаємодій на кількісні показники, перевіряти передумови гомогенності дисперсій, а також коректно виявляти приховані фактори у дослідженнях, що запобігає хибним висновкам через побічні артефакти вибірки.