

Лабораторна робота № 3
з курсу “Інтелектуальний аналіз даних”

ТЕМА: „Дисперсійний аналіз даних”

МЕТА: вивчення методики проведення дисперсійного аналізу статистичних даних на прикладі розв'язання конкретної задачі ІАД.

Теоретичні відомості

Дисперсія - ступінь розсіювання навколо середнього значення випадкової величини. У статистичному розумінні дисперсія є середнє арифметичне із квадратів відхилень величин від їх середнього арифметичного

Дисперсійний аналіз – це сукупність методів, які дозволяють перевіряти: чи змінюється середнє значення характеристик деяких об'єктів в залежності від дії деякого фактора або кількох факторів. Він дає змогу визначити вплив одного або декількох факторів на результативний показник.

Розв'язання задачі виміру зв'язку спирається на розкладення суми квадратів відхилень досліджуваних значень результативної ознаки від загальної середньої на окремі частини, які обумовлюють зміну цієї ознаки. Якщо сукупність розбита на групи, то при цьому розраховуються загальна, групова, середня з групових і міжгрупова дисперсії.

Загальна дисперсія (σ^2) – це середній квадрат відхилень окремих значень ознак (x) від їх середньої величини. Вона обчислюється за формулою

$$\sigma^2 = \sum (x - \langle x \rangle)^2 f / \sum f, \text{ або } \sigma^2 = \langle x^2 \rangle - \langle x \rangle^2$$

де $\langle x \rangle$ – загальна середня для всієї досліджуваної сукупності; f – обсяг сукупності (кількість одиниць).

Загальна дисперсія відображає варіацію досліджуваної ознаки за рахунок усіх умов, які впливають на неї у цій сукупності.

Групова дисперсія (σ_i^2) є середнім квадратом відхилень варіантів ознаки (x) від групової середньої величини. Розраховується за формулою

$$\langle \sigma_i \rangle^2 = \sum (x - \langle x_i \rangle)^2 f / \sum f$$

де $\langle x_i \rangle$ – групова середня; i – порядковий номер x та f в межах групи.

Групова дисперсія характеризує варіацію ознаки в межах групи за рахунок всіх інших факторів за виключенням того, який покладений в основу групування.

Щоб виміряти таку варіацію для сукупності в цілому, необхідно знайти середню із групових дисперсій.

Середня з групових дисперсій ($\langle \sigma_i^2 \rangle$) визначається за формулою

$$\langle \sigma_i \rangle^2 = \sum \sigma_i^2 f / \sum f$$

Середня з групових дисперсій характеризує випадкову варіацію в кожній окремій групі. Ця варіація виникає під впливом інших факторів, що не враховуються, і не залежить від ознаки-фактора, покладеної в основу групування.

Міжгрупова дисперсія (δ^2) або дисперсія групових середніх вимірює варіацію результативної ознаки за рахунок факторної ознаки, покладеної в основу групування. Її формула

$$\delta^2 = \sum (\langle x_i \rangle - \langle x \rangle)^2 f / \sum f$$

Про зв'язок між досліджуваними ознаками можна судити за допомогою коефіцієнта детермінації, який є відношенням міжгрупової дисперсії до загальної і записується у вигляді формули

$$p^2 = \delta^2 / \sigma^2.$$

Коефіцієнт детермінації показує ступінь участі факторної ознаки у формуванні загальної змінюваності результативної ознаки.

Розрізняють однофакторний та багатофакторний дисперсійний аналіз

1. Однофакторний дисперсійний аналіз

Нехай ми маємо k рівнів фактора. Специфікація моделі має вигляд

$$x_{ij} = a_i + \varepsilon_{ij}; \quad i = \overline{1, k}; \quad j = \overline{1, n},$$

де a_i - середнє значення, обчислене при i -му рівні фактора; ε_{ij} - випадкова величина, результат впливу неврахованих факторів, ε розподілена $N(0, \sigma^2)$

Приклад 1.

Кожний співак Нью-Йоркської Хорової спільноти в 1979 році офіційно доповідав про свій зріст. Голоси співаків поділяються від найнижчого за тоном до найвищого на такі типи: сопрано, альт, тенор, бас. Зазвичай 2 перші типи належать жінкам, 2 останні – чоловікам. Потрібно дослідити – як зріст впливає на голосовий діапазон співака чи співачки. Також треба зробити порівняння сопрано та альтів і, окремо, порівняння тенорів і басів.

Дані опитування містяться в файлі voice.txt, що має наступну структуру (рис.1)

Soprano	Alto	Tenor	Bass
64	65	69	72
62	62	72	70
66	68	71	72
65	67	66	69
60	67	76	73
61	63	74	71
65	67	71	72
66	66	66	68
65	63	68	68
63	72	67	71
67	62	70	66
65	61	65	68

Рис.1. Фрагмент вмісту файлу voice.txt

Для проведення аналізу спочатку занесемо дані у фрейм з двома стовпчиками-змінними: один відповідає зросту людини (Hei, залежна змінна), другий – тип голосу (Factor, фактор):

```
voice <- read.table(file.choose(), header=TRUE)
```

```
voice
```

```
Hei Factor
1 64 Soprano
2 62 Soprano
.....
130 66 Bass
```

Щоб запустити програму однофакторного дисперсійного аналізу в R-studio, скористаємось комбінацією функцій summary() та aov() (скорочення від ANOVA – analysis of variances). В аргументах вказуємо спершу залежну змінну, потім – фактор.

```
summary(aov(Hei~Factor))
```

```
Df Sum Sq Mean Sq F value Pr(>F)
Factor    3  956.5   318.8   44.7 <2e-16 ***
Residuals 126  898.7    7.1
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Як ми бачимо, досягнутий рівень значущості при перевірці гіпотези є $2 \cdot 10^{-16}$. Це означає, що при рівні значущості $p = 0,05$ гіпотезу про рівність середніх відхиляємо. Є зв'язок між зростом людини і тембром голосу.

Отже, зріст і тембр пов'язані. Але серед співаків у вибірці є і жінки, і чоловіки. Може, ефект залежності просто показує відмінність між жінками і чоловіками – жінки в середньому нижчі і їх тембр в середньому вищий. Чи буде така сама залежність всередині статі?

Вилучимо з вибірки чоловіків, для цього створимо новий фрейм `dal`, де змінна `Factor` не може приймати значення `Bass` і `Tenor`.

```
voice1<-da[as.character(da[, "Factor"])!="Bass" & (voice
[, "Factor"])!="Tenor",]
```

Запускаємо програму однофакторного дисперсійного аналізу.

```
summary(aov(voice1$Hei~ voice1$Factor))
```

```
Df Sum Sq Mean Sq F value Pr(>F)
voice1$Factor  1  0.5   0.519  0.075  0.784
Residuals    72 495.4   6.881
```

Досягнутий рівень значущості $p = 0,784$. Отже, серед жінок відсутній зв'язок між зростом і тембром голосу.

Зробимо такий самий аналіз всередині чоловіків.

```
voice2<- voice[as.character(da[, "Factor"])!="Soprano" & (voice
[, "Factor"])!="Alto",]
summary(aov(voice2$Hei~ voice2$Factor))
```

```
Df Sum Sq Mean Sq F value Pr(>F)
voice2$Factor  1 32.9   32.91  4.407 0.0405 *
Residuals    54 403.3    7.47
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Тут $p = 0,0405$. Отже, серед чоловіків суттєвий зв'язок між зростом і тембром.

Приклад 2. Провести дисперсійний аналіз варіації урожайності озимої пшениці за двома виробничими підрозділами. При цьому другий підрозділ вніс мінеральні добрива, а перший – ні.

В таблиці наведено посівні площі та урожайність озимої пшениці в господарстві за двома виробничими підрозділами

Підрозділ № 1 (не вносив добрив)					
1	50	20	1000	400	20 000
2	25	22	550	484	12 100
3	25	25	625	625	15 625

Разом	100	—	2175	1509	47 725
Підрозділ № 2 (вносив добрива)					
4	50	30	1500	900	45 000
5	75	35	2625	1225	91875
6	25	40	1000	1600	40 000
Разом	150	—	5125	3725	176 875
Всього по господарству	250	—	7300	5234	224 600

Розрахуємо спочатку середню врожайність по господарству: $\langle x \rangle = 7300/250 = 29,2$

Далі визначаємо:

Для підрозділу № 1:

1) групову середню: $\langle x_1 \rangle = 2175/100 = 21,75$

2) середній квадрат варіантів ознаки $\langle x_1 \rangle^2 = 77725/100 = 777,25$

3) загальну дисперсію $\sigma_1^2 = 477,25 - 21,75^2 = 4,19$

Для підрозділу № 2:

1) групову середню $\langle x_2 \rangle = 5125/150 = 34,17$

2) середній квадрат варіантів ознаки $\langle x_2 \rangle^2 = 176875/150 = 1179,17$

3) загальну дисперсію $\sigma_2^2 = 1179,17 - 34,17^2 = 12,11$.

Визначимо середню з групових дисперсій як середню арифметичну зважену із групових дисперсій:

$$\sigma_1^2 = \frac{\sum \sigma_i^2 f_i}{\sum f_i} = \frac{4,19 \cdot 100 + 12,11 \cdot 150}{100 + 150} = 8,94$$

Знайдемо міжгрупову дисперсію:

$$\delta^2 = \frac{\sum (\bar{x}_i - \bar{x})^2 f_i}{\sum f_i} = \frac{(21,75 - 29,2)^2 \cdot 100 + (34,17 - 29,2)^2 \cdot 150}{100 + 150} = 37$$

Тоді загальна дисперсія за урожайністю озимих зернових становитиме:

$$\sigma^2 = \sigma_i^2 + \delta^2 = 8,94 + 37 = 45,94$$

$$\eta^2 = \frac{37,00}{45,94} = 0,805$$

Розрахуємо коефіцієнт детермінації, або 80,5%.

$$\eta = \sqrt{\frac{\delta^2}{\sigma^2}} = \sqrt{\frac{37,00}{45,94}} = 0,897$$

Обчислимо кореляційне відношення

Це свідчить про те, що мінеральні добрива суттєво впливають на урожайність озимої пшениці.

2. Двофакторний дисперсійний аналіз

Нехай на досліджувану ознаку впливають одразу 2 фактори А і В. Ми маємо p рівнів фактора А і q рівнів фактора В. Таким чином, кожне спостереження X_{ijk} залежить від трьох індексів – рівня фактору А, рівня фактору В і номера спостереження. Специфікація моделі має вигляд

$$x_{ijk} = \mu + \alpha_i + \beta_j + \gamma_{ij} + \varepsilon_{ijk}; \quad i = \overline{1, p}; \quad j = \overline{1, q}; \quad k = \overline{1, n},$$

де μ – загальне середнє, α_i , β_j – ефекти впливу факторів А і В відповідно; γ_{ij} – ефект взаємодії; ε_{ijk} – випадкова величина, результат впливу неврахованих факторів (неспецифічна компонента), ε розподілена $N(0, \sigma^2)$

Потрібно дослідити, чи присутня залежність між кількістю помилок, яких припускаються щури при проходженні лабіринту, від їх оточуючого середовища та від генетичних властивостей. Дані експерименту занесені у файл rat.txt, що має наступну структуру (рис. 2)

ENVIRNMNT	ERRORS	STRAIN
Free	26	Bright
Free	14	Bright
Free	41	Bright
Free	16	Bright
Free	41	Mixed
Free	82	Mixed
Free	26	Mixed
Free	86	Mixed
Free	36	Dull
Free	87	Dull

Рис.2. Фрагмент вмісту файлу rat.txt

Назви змінних:

1. ENVIRONMET = Оточуюче середовище: FREE – вільне; RESTRCTED - обмежене.
2. STRAIN = Генетична характеристика: BRIGHT – чиста лінія «розумних» пацюків; MIXED - мішаної крові; DULL– чиста лінія «дурних» пацюків.
- 3.ERRORS = Кількість помилок, яких припустився щур при проходженні лабіринту.

Занесемо дані у фрейм з трьома стовпчиками-змінними: ERRORS – залежна змінна; ENVIRONMENT, STRAIN – фактори.

```
rat<-read.table(file.choose(),header=TRUE)
rat
attach(rat)
```

Запускаємо програму дисперсійного аналізу. В аргументах вказуємо, що перевіряємо вплив і середовища, і генетичних властивостей, і сукупності дій цих факторів.

```
z<-aov(ERRORS~ENVIRONMENT+STRAIN+ENVIRONMENT:STRAIN)
anova(z)
```

Analysis of Variance Table

Response: ERRORS

	Df	Sum Sq	Mean Sq	F value	Pr(>F)
ENVIRONMENT	1	5551.0	5551.0	5.8225	0.02670 *
STRAIN	2	7939.7	3969.9	4.1640	0.03264 *
ENVIRONMENT:STRAIN	2	16.1	8.0	0.0084	0.99160

Residuals 18 17160.8 953.4

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Як ми бачимо, гіпотезу про рівність середніх при зміні фактора середовища ENVIRONMENT відхиляємо, бо $p = 0,0267$ - вплив є. Аналогічно спостерігається вплив генетичного фактора STRAIN ($p = 0,03264$). А от впливу комбінації цих факторів нема: $p = 0,9916$.

Завдання на лабораторну роботу

1. Розглянути наведені в теоретичній відомостях методи і функції дисперсійного аналізу даних. За допомогою вбудованої довідки вивчити параметри функцій `aov()`, `summary()` і `anova()`.
2. Для масивів даних, що містяться в файлах `voice.txt` та `rat.txt`, провести однофакторний та багатофакторний дисперсійний аналіз згідно наведених вище прикладів.
3. Для власного набору даних провести дисперсійний аналіз, використовуючи описані вище функції (за необхідності провести очистку та структурування даних, проаналізувати отримані результати). В якості набору даних можна використати дані з сайту <http://data.worldbank.org>. Розгляньте на вибір два параметри: виробництво енергії (<http://data.worldbank.org/indicator/EG.EGY.PROD.KT.OE> . Таблиця даних знаходиться у файлі `eg.egy.prod.kt.oe_Indicator_en_csv_v2.csv`) або викиди вуглекислого газу (<http://data.worldbank.org/indicator/EN.ATM.CO2E.KT>. Таблиця даних знаходиться у файлі `en.atm.co2e.kt_Indicator_en_csv_v2.csv`). Можна також самостійно вибрати параметри для аналізу.

Вимоги до оформлення звіту

Захист лабораторної роботи проводиться при наявності звіту. Захист роботи виконується у встановлені терміни. Звіт повинен бути оформлений на папері стандартного формату А4

Звіт повинен містити такі розділи:

1. Постановку задачі, розв'язування якої виконується на лабораторній роботі.
2. Короткий опис основних теоретичних положень та алгоритмів, що застосовуються для розв'язування поставленої задачі та будуть використані при реалізації завдань.
3. Контрольні приклади та результати їх виконання. Викладач може запропонувати свої приклади для перевірки працездатності програми.