

Лабораторна робота № 4

з курсу “Інтелектуальний аналіз даних”

ТЕМА: „Кластерний аналіз даних. Ітераційні процедури та ієрархічна кластеризація за методом К-середніх.”

META: вивчення методики проведення кластерного аналізу статистичних даних на прикладі розв’язання конкретної задачі ІАД.

Теоретичні відомості

Кластерний аналіз – це метод багатомірного статистичного дослідження, до якого належать збір даних, що містять інформацію про вибіркові об’єкти, та упорядкування (розбиття) їх в порівняно однорідні, схожі між собою групи (кластери або класи).

Отже, завдання кластерного аналізу полягає в тому, щоб розбити об’єкти на групи (кластери) так щоб об’єкти в кожній групі були певним чином схожі. Перевагою кластерного аналізу ж те, що він дозволяє проводити розбиття об’єктів не по одному параметру, а по цілому набору ознак. Для цього вводяться відповідні показники, що характеризують певну міру близькості за всіма класифікаційними параметрами.

В результаті аналізу сукупності вхідних даних створюються однорідні групи у такий спосіб, що об’єкти всередині цих груп подібні між собою за деяким критерієм, а об’єкти з різних груп відрізняються один від одного.

Мета кластерного аналізу полягає в пошуку наявних структур, що виражається в утворенні груп схожих між собою об’єктів – кластерів. Водночас його дія полягає й у привнесенні структури в досліджувані об’єкти. Це означає, що методи кластеризації необхідні для виявлення структури в даних, яку нелегко знайти при візуальному обстеженні або за допомогою експертів. Кластерний аналіз дозволяє розглядати досить великий обсяг інформації і різко скорочувати, стискати великі масиви соціально-економічної інформації, робити їх компактними і наочними.

Основними завданнями кластерного аналізу є:

- розробка типології або класифікації досліджуваних об’єктів;
- дослідження та визначення прийнятних концептуальних схем групування об’єктів;
- висунення гіпотез на підставі результатів дослідження даних;
- перевірка гіпотез чи справді типи (групи), які були виділені певним чином, мають місце в наявних даних.

Призначення алгоритму побудови дерев кластеризації полягає в поступовому об’єднанні об’єктів в досить великі кластери, використовуючи заходи відстані і подібності між об’єктами.

На першому кроці кожен об’єкт є кластером. При переході до наступного кроку групи об’єктів об’єднуються в кластери на основі міри відстані і обраного методу. На кожному наступному кроці процедура повторюється для найбільш «близьких» один до одного кластерів.

Кластеризація може здійснюватися двома основними способами, зокрема за допомогою ієрархічних чи ітераційних процедур.

Ієрархічні процедури – послідовні дії щодо формування кластерів різного рангу, підпорядкованих між собою за чітко встановленою ієрархією. Найчастіше ієрархічні процедури здійснюються шляхом об'єднувальних дій. Вони передбачають такі операції:

- послідовне об'єднання подібних об'єктів з утворенням матриці подібності об'єктів;
- побудова дендрограми (деревоподібної діаграми), яка відображає послідовне об'єднання об'єктів у кластери;
- формування із досліджуваної сукупності окремих кластерів на першому початковому етапі аналізу та об'єднання всіх об'єктів в одну велику групу на завершальному етапі аналізу.

Ієрархічні алгоритми поділяються на **алгоритми з одинарним зв'язком** і **з повним зв'язком** (існують і інші підходи, але вони менш популярні). В алгоритмах з одинарним зв'язком відстанню між двома кластерами вважається мінімальна відстань між усіма парами елементів з цих двох кластерів. В алгоритмах з повним зв'язком відстанню вважається максимальна відстань між усіма парами елементів з двох кластерів.

Таким чином, алгоритми з повним зв'язком схильні знаходити більш компактні кластери. Алгоритми з одинарним зв'язком, навпаки, схильні виявляти сильно витягнуті і складні форми. На рис. 1. наведено класичний приклад роботи алгоритму одинарного (а) і повного (б) зв'язку.




Рис. 1. Розподіл на кластери

Видно, що алгоритм з одиночної зв'язок дав не самий адекватний результат. З іншого боку, алгоритми з повним зв'язком не здатні виявити концентричні кластери, такі як на рис. 2.




Рис. 2. Концентричні кластери

Таким чином, вибір алгоритму визначається конкретним завданням. Але на практиці, кластери складної форми зустрічаються рідко, тому частіше застосовуються алгоритми з повним зв'язком.

Ітераційні процедури полягають в утворенні з первинних даних однорівневих (одного рангу) ієрархічно не підпорядкованих між собою кластерів.

Одним із найбільш поширених способів проведення ітераційних процедур виступає **метод k-середніх**, застосування якого потребує здійснення таких кроків:

- 1) Вибрати k випадкових центрів в просторі, що містить вихідні дані. Обчислити багатовимірні середні (центрів тяжіння) виділених кластерів
- 2) Призначити кожен об'єкт з множини вихідних даних кластеру виходячи з того, який центр до нього ближче шляхом розрахунку Евклідової відстані кожної одиниці сукупності до визначених центрів тяжіння кластерів
- 3) Перерахувати центри кластерів використовуючи отриманий розподіл об'єктів
- 4) Якщо алгоритм не зійшовся, то перейти до п. 2. Типові критерії сходження алгоритму це або середньоквадратична помилка, або відсутність переміщень об'єктів з кластера в кластер.

Головним недоліком даного методу є збіжність до локального мінімуму і залежність результату від початкового розподілу. Крім того, потрібно заздалегідь знати передбачуване число кластерів k .

Існує безліч варіацій цього алгоритму, деякі з них намагаються вибрати найкраще початковий розподіл, інші дозволяють кластерам розбиватися на частини і об'єднуватися. Прикладом такої модифікації є алгоритм ISODATA, реалізований в Маткад і багатьох інших математичних бібліотеках.

Розглянемо деякі види парних відстаней між об'єктами, що використовуються для розбиття даних на кластери:

1. Евклідова відстань: $d_{rs}^2 = (x_r - x_s)(x_r - x_s)'$, де x_r, x_s - r і s рядки матриці X , $r = 1..m$, $s = 1..m$.
2. Стандартизована Евклідова відстань: $d_{rs}^2 = (x_r - x_s)D^{-1}(x_r - x_s)'$, де D - діагональна матриця. Діагональними елементами D є вибіркові дисперсії ознак багатовимірної випадкової величини $X_j, j=1..m$.
3. Відстань Махаланобіса: $d_{rs}^2 = (x_r - x_s)V^{-1}(x_r - x_s)'$, V - коваріаційна матриця, розрахована за вибіркою X .

$$d_{rs} = \sum_{j=1}^n |x_{rj} - x_{sj}|$$

4. Відстань по Манхетену:

$$d_{rs} = \left[\sum_{j=1}^n |x_{rj} - x_{sj}|^p \right]^{\frac{1}{p}}$$

5. Метрика Мінковського:

При $p=1$ метрика Мінковського еквівалентна відстані по Манхетену. При $p=2$ метрика Мінковського перетворюється в Евклідову відстань.

$$d_{rs} = \left[1 - \frac{x_r x_s'}{(x_r' x_r)^{\frac{1}{2}} (x_s' x_s)^{\frac{1}{2}}} \right]^{\frac{1}{2}}$$

6. Косинусна відстань:

7. Кореляційна відстань:

$$d_{rs} = 1 - \frac{(x_r - \bar{x}_r)(x_s - \bar{x}_s)'}{\left[(x_r - \bar{x}_r)(x_r - \bar{x}_r)' \right]^{\frac{1}{2}} \left[(x_s - \bar{x}_s)(x_s - \bar{x}_s)' \right]^{\frac{1}{2}}}, \text{ де } \bar{x}_r = \frac{1}{n} \sum_{j=1}^n x_{rj}, \bar{x}_s = \frac{1}{n} \sum_{j=1}^n x_{sj}.$$

(визначається як одиниця мінус вибіровий коефіцієнт кореляції між значеннями ознак багатовимірної випадкової величини. Вектори спостережень трактуються як вибірки)

8. Відстань Хемінга: $d_{rs} = (\#(x_{rs} \neq x_{rs}))/n$.

Кластеризація даних на мові R

Основні процедури кластерного аналізу реалізовані в R у пакеті stats, cluster. Є також і інші пакети, які необхідно завантажити і встановити окремо. Наприклад, pvclust.

Розглянемо як приклад множину O, що складається з 25 об'єктів (N=25), які мають єдину ознаку (n=1); результати спостережень зведено в матрицю (для даного прикладу – вектор) .

$$X = \{3,4,7,4,3,3,4,4,7,11,6,6,6,3,4,4,4,4\}^T$$

```
data=data.frame(c(3,4,7,4,3,3,4,4,7,11,6,6,6,3,4,4,4,4)) #визначення матриці відстаней
```

Проведемо *ієрархічну кластеризацію* використовуючи функцію `dist()` , аргументами якої є вхідний набір даних, які потрібно розбити на кластери та метод, за яким проводиться розбиття

```
matr_D=dist(data, method = "euclidean")
```

Для наочності відобразимо результат графічно за допомогою дендрограми

```
tree=hclust(matr_D)
```

```
plot(tree) #побудова дендрограми
```

```
rect.hclust(tree, k= 5,border=4) #виділення кластерів боксами
```

Для *кластеризації даних за методом k-середніх* використаємо стандартну функцію `kmeans(x, n, m)`, де x- набір даних, n - очікувана кількість кластерів, m - максимальна кількість ітерацій.

```
cl=kmeans(matr_D,3,10)
```

```
cl$cluster #виводимо отримані кластери в консоль
```

Розглянемо приклад кластеризації даних на мові R в середовищі R-studio засобами бібліотеки pvclust. В якості даних для аналізу використаємо стандартний набір даних з пакету "MASS"

```
data(Boston, package = "MASS") #завантажуємо дані в змінну Boston
```

проводимо розрахунок BP- и AU-ймовірностей для вузлів, відстань між даними визначаємо як евклідову відстань

```
boston.pv <- pvclust(Boston, nboot=100, method.dist = "euclidean",  
method.hclust = "average", quiet = TRUE)
```

```
plot(boston.pv) #графічно будуємо кластери (дендрограма)
```

```
pvrect(boston.pv, alpha=.95, border = 'green') #виділення кластерів боксами
```

Аналогічно для порівняння проведемо розбиття на кластери вказаного набору даних за допомогою стандартної функції `kmeans(x, n, m)`

```
Boston <- t(Boston) #транспонуємо таблицю
```

```
kmeans(Boston, 3, 10) # кластеризація за методом к-середніх, евклідова відстань
```

Розглянемо ще один приклад кластеризації даних на мові R в середовищі R-studio.

Нехай в деякому файлі **stocks.csv** маємо котирування групи компаній з різних областей за два роки з періодом 1 день. Чи можна на основі цих даних об'єднати акції в групи? Для цього проаналізуємо дані засобами кластерного аналізу. Оскільки ціни різних акцій відрізняються дуже сильно, і абсолютна величина ціни не інформативна, використаємо відносну зміну – замість самої ціни використаємо логарифмічну зміну ціни:

$$X_i = \log(C_i) - \log(C_{i-1}), \text{ де } C_i - \text{ціна закриття в } i\text{-ий день.}$$

Завантажимо файл з даними та прологарифмуємо ціни

```
x <- read.table(file = "stocks.csv", sep=',', header=TRUE)
x <- log(x) #логарифмуємо ціни
```

Далі слід відобразити вміст файлу та проаналізувати його - чи є дані, що не будуть використовуватись як параметри кластеризації. В даному файлі - це стовпчик з датою. Вилучаємо його з аналізу:

```
x <- x[-1] #Вилучаємо його з масиву стовпець з датою.
```

Для кластеризації даних за методом к-середніх використаємо стандартну функцію **kmeans(x, n, m)** з кількістю очікуваних кластерів **n=5**

```
x <- apply(x, 2, diff) #обчислюємо різницю між послідовними елементами
x <- t(x) #транспонуємо таблицю
kmeans(x, 5, 10000) # розбиваємо на 5 кластерів, максимум 10000 ітерацій.
```

Отримуємо такий результат

1	2	3	4	5
RASP	AFLT, PMTL, PLZL, MMBM, MTSI, VZRZ	GAZP, LKOH, VTBR, URKA, TRNFP, SIBN, SBER, ROSN, GMKN, SNGS	OGK1, OGK2, OGK5	KMAZ, AVAZ

В результаті кластеризації отримали наступне: автовиробники потрапили в п'ятий кластер, нафтовидобувні компанії і великі банки в третій, всі генеруючі компанії в четвертий. Якщо запустити цей алгоритм знову, то результат може вийде інший, але тенденція, проте, збережеться. Зазначимо, що кількість очікуваних кластерів (в даному прикладі - 5) має задавати аналітик.

Якщо очікувана кількість кластерів не відома зовсім, можна провести ієрархічну кластеризацію та відобразити результат графічно за допомогою дендрограми.

Для цього замість функції **kmeans()** використаємо наступну **hclust()**:

```
hc <- hclust(dist(x)) #ділимо набір даних на групи
plot(hc) #виводимо результати графічно - будуємо дендрограму
pvrect(x.pv, alpha=.95) #виділення боксами
Отримуємо наступний результат (рис.3)
```




Рис. 3. Дендрограма, що відображає отримані кластери

На рис.3. видно традиційні сектора економіки та виколоті точки. Виколоті точки часто можуть стати предметом особливого дослідження, адже якщо компанія поводить себе не як всі в її галузі, значить вона щось робить по-іншому. Знання подібної інформації може дати додаткову перевагу аналітику.

Завдання на лабораторну роботу

1. Розглянути наведені в теоретичних відомостях методи і функції кластерного аналізу даних. За допомогою вбудованої довідки вивчити параметри функцій `hclust()` і `kmeans()`.
2. Для власного набору даних провести розрахунок парних відстаней між об'єктами та кластерний аналіз, використовуючи метод метод k-середніх (побудувати необхідні залежності, проаналізувати отримані результати).
3. Для масиву даних, що містяться в файлі `stocks.csv`, сформувати та візуалізувати ієрархічне дерево кластерів (дендрограму) за допомогою різних алгоритмів, використовуючи відповідні функції пакету R-studio. Провести аналіз отриманих результатів.
4. Проведіть кластерний аналіз набору даних з сайту <http://data.worldbank.org>. Виконайте кластеризацію країн за рівнем безробіття використовуючи дані з файлу `sl.uem.totl.zs_Indicator_en_csv_v2.csv`.

Вимоги до оформлення звіту

Захист лабораторної роботи проводиться при наявності звіту. Захист роботи виконується у встановлені терміни. Звіт повинен бути оформлений на папері стандартного формату A4

Звіт повинен містити такі розділи:

1. Постановку задачі, розв'язування якої виконується на лабораторній роботі.

2. Короткий опис основних теоретичних положень та алгоритмів, що застосовуються для розв'язування поставленої задачі та будуть використані при реалізації завдань.
3. Контрольні приклади та результати їх виконання. Викладач може запропонувати свої приклади для перевірки працездатності програми.