

Лабораторна робота № 5
з курсу “Інтелектуальний аналіз даних”

ТЕМА: „Кластерний аналіз даних. Карти Кохонена”

МЕТА: вивчення методики проведення кластерного аналізу статистичних даних та засобів візуалізації отриманих кластерів на прикладі розв’язання конкретної задачі аналізу даних.

Теоретичні відомості

Карти Кохонена, що самоорганізуються (SOM), є потужним інструментом, який об’єднує дві важливі задачі аналізу даних – кластеризація і проектування, тобто дозволяють здійснити візуалізацію багатомірних даних на площині. Налаштування SOM відноситься до алгоритмів навчання без вчителя.

Мережа Кохонена має всього два шари: вхідний та вихідний, що складається з радіальних нейронів впорядкованої структури (вихідний шар називають також шаром топологічної карти, або "екраном"). Нейрони вихідного шару розташовуються у вузлах двовимірної решітки з прямокутними або шестикутними осередками. Кількість нейронів в решітці визначає ступінь деталізації результату роботи алгоритму. Тому, чим більше нейронів, тим більша точність отриманої карти.

Карта Кохонена в ході свого навчання аналізує характер розташування точок вхідного шару в m -мірний простір і намагається відтворити на виході нейронної мережі топологічний порядок і міру регулярності вихідних даних. Для підбору вагових коефіцієнтів використовується модифікований алгоритм навчання Хебба, який враховує не тільки внесок відповідного нейрону, а й найближчих його сусідів.

На стадії ініціалізації всім ваговим коефіцієнтам привласнюються невеликі випадкові значення. На виході мережі подаються послідовно в випадковому порядку образи об’єктів вхідного шару і для кожного з них вибирається "нейрон-переможець" з мінімальним відстанню (рис. 1). Визначається підмножина "найближчого оточення", радіус якого зменшується з кожною ітерацією.




Рис. 1. Схема активації нейронів в мережі Кохонена

Кроки алгоритму повторюються, поки вихідні значення мережі не будуть стабілізовані із заданою точністю. При цьому якість проектування багатомірних даних на площину досягається в SOM на декількох рівнях: збереження топології (тобто на множинах точок вихідних даних і нейронів навченої мережі структура сусідства однакова), збереження порядку (тобто відстані між еквівалентними парами точок пропорційні) і збереження метричних властивостей при стисненні простору.

"Проекційний екран" в результаті навчання набуває властивостей впорядкованої структури, в якій величини синапсів нейронів плавно змінюються уздовж двох вимірів. Колір і розташування фрагментів двовимірної решітки використовується для аналізу закономірностей, що пов'язуються з компонентами набору даних. Зокрема, з кожним вузлом (нейроном) можуть асоціюватися локальні групи вихідних об'єктів, які можуть служити потенційними центрами кластерів.

Для навчання мережі зазвичай використовуються функції `somgrid()` і `som()` з пакету `kohonen`. По завершенні ітераційного процесу функція `plot()` стає доступним для візуалізації наступний комплект карт:

"Codes" - показується розподіл по решітці співвідношення міри участі окремих вихідних змінних;

"Counts" - число вихідних об'єктів в кожному вузлі мережі;

"Mapping" - координати вихідних об'єктів на сформованій карті;

"Property", "quality", "dist.neighbours" - різними кольорами зображується цілий набір властивостей кожного вузла: міри участі окремих вихідних

змінних, міри парних або середніх відстаней між нейронами тощо.

В якості набору вхідних даних для кластеризації розглянемо стандартний набір Boston з пакету MASS. Щоб графік "codes" був більш лаконічний, з вихідного набору ознак виділимо 7 змінних, імовірно найбільш значущих для кластеризації (рис. 2). Виконаємо попередньо стандартизацію даних.

```
data(Boston, package = "MASS")
VarName = c("indus", "dis", "nox", "medv", "lstat", "age",
"rad")
# виділяємо 7 змінних для навчання мережі SOM
data_train <- Boston[, VarName]
data_train_matrix <- as.matrix(scale(data_train))
#підключаємо бібліотеку
library(kohonen)
set.seed(123)
som_grid <- somgrid(xdim = 9, ydim = 6, topo = "hexagonal")
#вказуємо першим параметром - 9, тобто 506 ділянок Бостона будуть
організовуватись на 54 нейронах вихідного шару, другий та третій
параметр функції вказує створити для результуючої карти гексагональну
решітку
som_model <- som(data_train_matrix, grid = som_grid, rlen = 100,
alpha = c(0.05,0.01), keep.data = TRUE)
#будуємо графік (рис.2)
plot(som_model, type = "changes")
```




Рис. 2. Зниження середньої відстані до найближчих нейронів в ході 100 ітерацій

(rlen) навчання мережі SOM при заданих значеннях параметра alpha

Виконаємо візуальне представлення карт Кохонена за різних параметрів функції plot().

```
# Задаємо палітру кольорів для карти
coolBlueHotRed <- function(n, alpha = 1)
{ rainbow(n, end = 4/6, alpha = alpha)[n:1] }
par(mfrow = c(2, 1))
# визначаємо кількість об'єктів, пов'язаних з кожним вузлом
plot(som_model, type = "counts", palette.name = coolBlueHotRed)
# визначаємо середню відстань від об'єктів вузла до прототипів
plot(som_model, type = "quality", palette.name = coolBlueHotRed)
```




Рис. 3. Карти SOM типів "counts" та "quality"

Тип карти "mapping" дозволяє отримати розподіл об'єктів по вузлах, що задовольняє будь-якій заданій умові. Наприклад, потрібно виділити ділянки з низьким ступенем афроамериканців (black - ознака, яка в налаштуванні мережі не використовувалась). А також показати, як при цьому розподіляються міри участі окремих вихідних змінних:

```
colB <- ifelse(Boston$black <= 100, "red", "gray70")
```

І.А.Д. Лабораторний практикум. 2020

```

par(mfrow = c(2, 1))
plot(som_model, type = "mapping", col = colB, pch = 16)
plot(som_model, type = "codes")

```




Рис. 4. Карти SOM типу "mapping" та "codes"

Оскільки об'єднана карта "codes" не завжди добре інтерпретується, можна отримати карту розподілу будь-якого показника за його стандартизованою або натуральною шкалою (рис. 5):

```

par(mfrow = c(2, 1))
plot(som_model, type = "property",
     property = som_model$codes[[1]][,1],
     main = "indus - частка будинків, що продаються в роздріб",
     palette.name = coolBlueHotRed)
var_unscaled <- aggregate(as.numeric(data_train[, 3]),
                          by = list(som_model$unit.classif),
                          FUN = mean, simplify = TRUE)[, 2]
plot(som_model, type = "property", property = var_unscaled,
     main = "nox - вміст окисів азоту",
     palette.name = coolBlueHotRed)

```




Рис. 5. Карти SOM для стандартизованого та вихідного показника

Значення активації кожного нейрона можна використовувати для групування вузлів. Задамо число кластерів $k = 5$ та виконаємо ієрархічну кластеризацію (за замовчуванням використовуються `method = "complete"` і `distance = "euclidean"`). Можна побудувати карти типу `"mapping"` (з мітками об'єктів) або `"codes"` (з розподілом частки вкладу змінних). Зупинимося на другому типі.

```
mydata <- as.matrix(som_model$codes[[1]])
# викоистовуємо ієрархічну кластеризацію з k=5
som_cluster <- cutree(hclust(dist(mydata)), 5)
# визначаємо палітру кольорів карти
pretty_palette <- c("#1f77b4", "#ff7f0e", "#2ca02c",
                   "#d62728", "#9467bd", "#8c564b", "#e377c2")
# обираємо різні кольори для кластерів вузлів та змінні
plot(som_model, type = "codes",
     bgcol = pretty_palette[som_cluster])
add.cluster.boundaries(som_model, som_cluster)
```




Рис. 6. Кластеризація вузлів карти SOM

Зазвичай метод Кохонена розглядається як емпіричний алгоритм, а висновки (в першу чергу, якісні) про структуру даних робляться на основі візуального аналізу представлених карт. Основні труднощі застосування SOM, полягають в інтерпретації топології мережі і зв'язуванні її окремих ділянок з деякими конкретними узагальненнями з предметної області.

Однак алгоритм SOM знайшов широке застосування в ГІС-технологіях, оскільки легко реалізувати інформаційний ланцюжок від вихідної таблиці до вузлів решітки, а від них - до конкретних координат на географічній карті. Наприклад, учасники колективу "Dublin R Users Group" використовуючи результати перепису населення 2011 р розбили територію Дубліна на 18500 маленьких майданчиків і описали, яке проживає на них населення з використанням 767 змінних з 15 розділів. На ресурсах (<https://www.r-bloggers.com>, <http://www.slideshare.net>) доступні повний комплект вихідних даних, докладний опис і скрипти R. Основні результати представлені на рис. 7.



Рис. 7. Кластерна форма карти SOM і її відображення на карті Дубліна (категорії від 1 до 6 зв'язуються з градаціями житлової забудови і забезпеченості населення - від нетрів до елітних районів)

Завдання на лабораторну роботу

1. Розглянути наведені в теоретичній відомостях методи і функції кластерного аналізу даних. За допомогою вбудованої довідки вивчити параметри функцій `somgrid()`, `par()` та `somgrid()`.
2. Для масиву даних, що містяться в наборі Boston з пакету MASS, сформувати та візуалізувати карти Кохонена за різних відних параметрів (інша к-сть змінних для навчання мережі SOM, к-сть кластерів, інші параметри функції `somgrid()` та `plot()` відповідно) використовуючи відповідні функції пакету R-studio. Провести аналіз отриманих результатів.
3. Проведіть кластерний аналіз для власного набору даних або набору даних з сайту <http://data.worldbank.org>. Можна також самотійно вибрати параметри для аналізу. Провести аналіз отриманих результатів.