

Лабораторна робота № 7

з курсу “Інтелектуальний аналіз даних”

ТЕМА: Прогнозування значень часових рядів. Однокрокове прогнозування

МЕТА: вивчення методики проведення прогнозування значень часових рядів на прикладі розв'язання конкретних завдань ІАД.

Теоретичні відомості

Часовий ряд (time series) – послідовність спостережень значень деякої змінної, зроблених через рівні проміжки часу. Кожен рівень часового ряду формується під впливом великого числа факторів, які умовно можна підрозділити на групи:

- **тренд** або фактори, що формують тенденцію ряду (наприклад, інфляція впливає на збільшення розміру середньої заробітної плати);
- **фактори, що формують циклічні коливання ряду** (наприклад, рівень безробіття в курортних містах у зимовий період вище по порівнянню з літнім);
- **випадкові фактори.**

Під **трендом** розуміється стійка систематична зміна процесу протягом тривалого часу. Оцінка тренда здійснюється параметричним і непараметричним методами. Параметричний метод полягає в підборі гладкої функції, що описувала б тенденцію ряду: лінійний тренд, поліном і т.д. Непараметричний метод використовується, коли не можна підібрати гладку функцію й полягає в механічному згладжуванні часових рядів методом ковзного середнього.

У часових рядах економічних процесів можуть мати місце більш-менш регулярні коливання. Якщо вони строго періодичні або їх характер близький до таких і завершуються протягом одного року, то їх називають сезонними коливаннями. Оцінка сезонної компоненти здійснюється двома способами: за допомогою тригонометричних функцій і методом сезонних індексів.

В загальному, прогнозування складається з наступних кроків: оцінка й видалення тренда, оцінка й видалення сезонної компоненти, побудова математичної прогнозної моделі й виконання прогнозу.

Прогнозування значень часового ряду на мові R

Перше, що потрібно зробити, щоб проаналізувати дані відповідного часового ряду – прочитати їх в R і вивести цей часовий ряд на екран. Це можна зробити за допомогою функції `scan()`, яка розглядає масив даних, зафіксованих через певні проміжки часу як простий текстовий файл з одною колонкою.

Наприклад, файл `kings.dat` (джерело - <http://robjhyndman.com/tsdldata/misc/kings.dat>) містить дані років життя королів Англії послідовно, починаючи з Вільяма Завойовника. Зчитати дані файлу в R можна наступним чином:

```
kings<-scan("http://robjhyndman.com/tsdldata/misc/kings.dat", skip=3)
```

Тут використано параметр `skip` функції `scan()`, що визначає кількість рядків з початку файлу, які потрібно пропустити.

Після того, як дані прочитано, потрібно зберегти їх в об'єкті типу часовий ряд, що б мати

змогу використовувати стандартні функції R для аналізу даних часових рядів. Для зберігання даних в об'єкті часового ряду призначена функція `ts()`.

Наприклад, зберегти даних змінної `kings` як об'єкт часового ряду можна так:

```
kingsts <- ts(kings, start = 1, end= 42, frequency = 1 )
```

Аргумент `start` використано, щоб вказати дату, з якої починається часовий ряд; аргумент `frequency` (частота) дозволяє задати крок для наступних часових даних.

Часто набір послідовних даних, що аналізуються, може бути складений на інтервалах менших ніж один рік, наприклад, по місяцях або кварталах. В цьому випадку можна вказати кількість вимірювань зроблених за рік, використовуючи параметр `frequency` функції `ts()`. Для часових рядів за місяцями `frequency = 12`, а для даних за кварталами `frequency = 4`.

Також можна вказати перший рік, в який збиралися дані, і перший інтервал в році за допомогою параметра `start` функції `ts()`. Наприклад, якщо перша точка даних відповідає другому кварталу 1986 року, потрібно встановити `start = c(1986,2)`.

Графічне представлення часових рядів

Після того, як дані прочитано та сформовано часовий ряд, потрібно побудувати графік даних ряду за допомогою функції `plot.ts()`.

Наприклад, графік часового ряду віку смертей 42 королів Англії будуємо так (рис. 1):

```
plot.ts(kingsts)
```




Рис. 1.

З графіку видно, що часовий ряд, ймовірно, може бути описаний за допомогою адитивної моделі, оскільки випадкові флуктації в даних приблизно постійні в часі.

Розклад часового ряду

Розклад часового ряду передбачає поділ його на складові компоненти. Зазвичай це тренд, нерегулярна складова і сезонна компонента (якщо це періодичний ряд).

Для оцінки трендової складової в неперіодичних тимчасових рядах, які можуть бути описані адитивною моделлю, часто використовується метод згладжування (наприклад, обчисленням простого змінного середнього).

Для згладжування ряду методом змінного середнього може бути використана функція `SMA()` пакета «TTR». Для використання цього спочатку необхідно встановити пакет «TTR» та завантажити відповідну бібліотеку:

```
library("TTR")
```

Для використання функції `SMA()` необхідно вказати порядок простого змінного середнього, використовуючи параметр `n`. Наприклад, щоб обчислити просте ковзне середнє близько 5 в функції `SMA` встановлюємо `n = 5`.

Розглянутий вище часовий ряд років смерті 42 королів Англії не є періодичним і може бути описаний адитивною моделлю, оскільки випадкові флуктації в даних майже постійні у всій вибірці.




Рис. 2.

Для згладжування часового ряду використаємо просте ковзне середнє близько 3 і виведемо результуючий графік

```
kingstsSMA3 <- SMA(kingsts,n=3)  
plot.ts(kingstsSMA3)
```




Рис. 3.

З рисунку видно, що множина випадкових флуктуації все ще проявляється в часовому згладженому ряді. Щоб збільшити точність можна провести згладжування даних методом простим ковзним середнім більшого порядку. Наприклад (рис. 4)

```
kingstsSMA8 <- SMA(kingsts,n=8)
plot.ts(kingstsSMA8)
```




Рис. 4.

Дані, згладжені за допомогою простого змінного середнього близько 8, дають прозору картину складової тренда і можна бачити, що тривалість життя королів, ймовірно, знижувалася з приблизно 55 років до приблизно 38 років в період перших 20 королів, а потім збільшувалася до 73 років до кінця правління сорокових королів в часі ряду.

Розклад періодичних даних

Періодичні дані складаються зі складових тренда, періодичної складової і нерегулярної складової. Щоб оцінити складову тренда і періодичну складову періодичного часового ряду, який може бути описаний адитивною моделлю, можна використовувати функцію `decompose()`, яка повертає список об'єктів в якості результату, що містять оцінки періодичної складової, тренда і нерегулярної компоненти, що зберігаються в іменування елементів цього списку об'єктів, які називаються «seasonal», «trend» і «random» відповідно.

Розглянемо розклад на компоненти часового ряду, що містить дані про народжуваність в Нью-Йорку, з січня 1946 по грудень 1959 (дані доступні в файлі <http://robjhyndman.com/tsdldata/data/nybirths.dat.>) (рис.5).

Для графічного виведення результатів використано функцію `plot()`,
`plot(birthstsccomponents)`




Рис. 5.

Виключення періодичної складової

Якщо є періодичний часова ряд, який може бути описаний адитивною моделлю, можна виключити сезонну компоненту з вихідного часового ряду, використавши оцінку сезонної компоненти, проведену функцією `decompose()`.

Наприклад, виключити сезонну складову часового ряду, що відображає кількість народжень в Нью Йорку можна так:

```
birthstscomponents <- decompose(birthsts)
birthstsseasonallyadjusted <- birthsts -birthstscomponents$seasonal
```

Після цього можна вивести графік часового ряду без сезонної складової за допомогою функції `plot()`:

```
plot(birthstsseasonallyadjusted)
```

Прогнозування

Для прогнозування можна використати алгоритм ARIMA.. Для цього спочатку необхідно встановити пакет «forecast» та завантажити відповідну бібліотеку:

```
library("forecast")
```

Для отримання прогнозу можна використати функції `auto.arima()` та `forecast()`.

На рис. 6. наведено результат прогнозування значень деякої величини (синя ділянка).




Рис. 6.

Видно, що згідно побудованого прогнозу величина буде зменшуватись. Варто зауважити, що для короткочасних прогнозів даний метод часто дає кращі результати, ніж нейронні мережі.

Завдання на лабораторну роботу

1. Розглянути наведені в теоретичних відомостях методи і функції прогнозування за допомогою часових рядів. За допомогою вбудованої довідки вивчити параметри функцій `scan()`, `ts()`, `plot.ts()`, `SMA()`, `decompose()`.
2. Для масиву даних, що містяться в файлі `nybirths.dat` та відображають щомісячні дані народжуваності в м. Нью-Йорк, отримані в період з січня 1946 по грудень 1959 (можна завантажити з сайту проф. Роба Хиндмана "<http://robjhyndman.com/tsdldata/data/nybirths.dat>") провести прогнозування даних, використовуючи наведені вище алгоритми та відповідні стандартні функції мови R.

3. Провести прогнозування динаміки формування цін на нафту, використовуючи джерело даних Quandl.

Для цього потрібно встановити пакет "Quandl" (`install.packages("Quandl")`) та сформувати наступні набори даних, що містять ціну на нафту марки «Бrent»

```
library(Quandl)
oil.ts      <- Quandl("DOE/RBRTE",      trim_start="1987-11-10",
trim_end="2015-01-01", type="zoo")
oil.tsw     <- Quandl("DOE/RBRTE",      trim_start="1987-11-10",
trim_end="2015-01-01", type="zoo", collapse="weekly")
oil.tsm     <- Quandl("DOE/RBRTE",      trim_start="1987-11-10",
trim_end="2015-01-01", type="ts", collapse="monthly")
```

Вимоги до оформлення звіту

Захист лабораторної роботи проводиться при наявності звіту. Захист роботи виконується у встановлені терміни. Звіт повинен бути оформлений на папері стандартного формату А4

Звіт повинен містити такі розділи:

1. Постановку задачі, розв'язування якої виконується на лабораторній роботі.
2. Короткий опис основних теоретичних положень та алгоритмів, що застосовуються для розв'язування поставленої задачі та будуть використані при реалізації завдань.
3. Контрольні приклади та результати їх виконання. Викладач може запропонувати свої приклади для перевірки працездатності програми.