

Лабораторна робота № 8

з курсу “Інтелектуальний аналіз даних”

ТЕМА: Пошук асоціативних правил на мові R. Алгоритм Apriori

META: вивчення методики проведення пошуку асоціативних правил за допомогою алгоритму Apriori на прикладі розв'язання конкретних завдань ІАД.

Теоретичні відомості

Нехай $I = \{i_1, i_2, \dots, i_m\}$ – множина елементів, D – множина транзакцій, де кожна транзакція T – це набір елементів з I , $T \subseteq I$.

Кожна *транзакція* – це множина елементів (подій), що відбулися одночасно, і являє собою *бінарний вектор*, де $t[k] = 1$, якщо i_k елемент присутній у транзакції, інакше $t[k]=0$. Транзакція T містить X , певний набір елементів з I , якщо $X \subseteq T$.

Асоціативним правилом (association rule) називається імплікація $X \rightarrow Y$, де $X \subset I$, $Y \subset I$ та $X \cap Y$ утворює порожню множину.

Вірогідність правила показує яка імовірність того, що з X випливає Y .

Методи пошуку асоціативних правил призначені для знаходження всіх правил $X \rightarrow Y$, причому підтримка і вірогідність цих правил повинні бути вище деяких наперед визначених порогів, названих відповідно *мінімальною підтримкою* (minsupport) і *мінімальною вірогідністю* (minconfidence).

Задача знаходження асоціативних правил розбивається на дві підзадачі:

1) знаходження всіх наборів елементів, що задовольняють порогові minsupport. Такі набори елементів називаються такими, що часто зустрічаються;

2) генерація правил зі знайдених наборів елементів з вірогідністю, що задовольняє порогові minconfidence.

Узагальненим асоціативним правилом (generalized association rule) називається імплікація $X \rightarrow Y$, де $X \subset I$, $Y \subset I$ та $X \cap Y$ утворює порожню множину і де жоден з елементів, що входять у набір Y , не є предком жодного елемента, що входить у X . Підтримка і вірогідність підраховуються так само, як і у випадку асоціативних правил.

Правило $X \rightarrow Y$ називається узагальненим, тому що елементи, які входять у нього можуть знаходитися на будь-якому рівні таєсономії. Також X називається предком Y та Y – нащадком X .

Програмні засоби реалізації методу пошуку асоціативних правил на мові R – бібліотеки `arules`, `arulesViz`

Сфери застосування асоціативних правил:

- ✓ роздрібна торгівля: визначення товарів, які варто просувати спільно; вибір місцезнаходження товару у крамниці; аналіз споживчого кошика; прогнозування попиту
- ✓ маркетинг: пошук ринкових сегментів; тенденції споживчої поведінки
- ✓ сегментація клієнтів: виявлення спільних характеристик клієнтів компанії; виявлення груп покупців
- ✓ оформлення каталогів, аналіз збутових кампаній фірми; визначення послідовностей покупок клієнтів
- ✓ аналіз Web-логів

Завдання на лабораторну роботу

1. Підключіть необхідні для роботи бібліотеки (`arules`, `arulesViz`).
2. Завантажте до R дані з інформацією про “ринковий кошик” з файлу `groceries.csv` (команда `read.transactions()`) та створіть об’єкт `itemMatrix`. (зверніть увагу на особливості структури файлу з транзакціями).
3. Отримайте інформацію про сформований масив транзакцій (команди `inspect()` та `summary()`).
4. Побудуйте графік розподілу частот зустрічальності ознак
(`itemFrequencyPlot(im'я змінної, support=___, cex.names=___)`),
Оберіть значення підтримки та розміру підписів такими, що найкраще візуалізують дані. Формування правил здійснюється функцією `apriori()` з зазначенням порогових значень підтримки та достовірності:

```
rules<-apriori(im'я змінної, parameter=list(support=___, confidence=___)).
```

5. Для вирішення завдання виявлення характерних особливостей груп товарів, нас цікавлять, у першу чергу, високоякісні правила, що мають відповідну ознаку групи у правій частині. Тоді товар можна буде легко впізнати за його оточенням:

```
rules_назва товару<-subset(rules, subset=rhs %in% "назва
товару" & lift>задане значення параметра)
inspect(head(rules_назва товару, n=кількість правил, які
необхідно вивести, by="support"))
```

```
plot(head(sort(rules_назва товару, by="support", кількість
правил)), method ="paracoord")
```

Графік у паралельних координатах (method ="paracoord") показує, як формуються комбінації ознак правої частини при зростанні її розміру, а товщина ліній відповідає рівню підтримки.

Метод "graph" функції plot() показує правила та складові їх ознаки у вигляді графа, розмір вузлів якого пропорційний рівню підтримки кожного наявного правила

```
plot(head(sort(rules_назва товару, by="support", кількість
правил)), method ="graph",
control=list(nodeCol=grey.colors(10), edgeCol=grey(0.7),
alpha=1))
```

Вимоги до оформлення звіту

Захист лабораторної роботи проводиться при наявності звіту. Захист роботи виконується у встановлені терміни. Звіт повинен бути оформлений на папері стандартного формату A4